Dịch máy Anh–Việt sử dụng Seq2Seq LSTM với Attention và Transformer: Đề xuất nghiên cứu

Tú (MSSV: điền mã) **Trung (MSSV: điền mã)** **Đức (MSSV: điền mã)**
Nhóm: điền mã nhóm

Abstract

Đề tài nghiên cứu bài toán dịch máy thần kinh từ tiếng Anh sang tiếng Việt bằng hai kiến trúc: Seq2Seq LSTM kết hợp cơ chế Attention và Transformer Encoder–Decoder. Nhóm sử dụng bộ dữ liệu song ngữ PhoMT, xây dựng quy trình tiền xử lý và huấn luyện thống nhất, sau đó so sánh chất lượng bản dịch bằng corpus BLEU. Nghiên cứu tập trung vào việc tự cài đặt các thành phần cốt lõi, phân tích lỗi dịch và trực quan hóa attention. Do hạn chế về tài nguyên tính toán, nhóm dự kiến tiến hành thí nghiệm trên tập con của PhoMT bằng GPU miễn phí.

1 Giới thiệu

Dịch máy thần kinh (Neural Machine Translation, NMT) sử dụng mạng học sâu để ánh xạ một chuỗi ngôn ngữ nguồn thành chuỗi ngôn ngữ đích. Seq2Seq là một hướng tiếp cận nền tảng, trong khi Attention giúp mô hình khai thác thông tin từ các vị trí khác nhau của câu nguồn (Bahdanau et al., 2015). Transformer thay thế các bước tính toán hồi quy bằng cơ chế self-attention (Vaswani et al., 2017).

Mục tiêu của nhóm là tự cài đặt và so sánh hai kiến trúc trên cùng bài toán dịch **Anh sang Việt**, qua đó nghiên cứu sự khác biệt về chất lượng dịch, tốc độ huấn luyện và các dạng lỗi thường gặp.

2 Dữ liệu

Nhóm sử dụng PhoMT, bộ dữ liệu song ngữ Việt–Anh quy mô lớn được giới thiệu bởi Doan et al. (2021). Bộ dữ liệu có 3.015.869 cặp câu, gồm 2.977.999 cặp train, 18.719 cặp validation và 19.151 cặp test.

Nhóm giữ nguyên cách chia dữ liệu được công bố, chỉ sử dụng tập train để xây dựng tokenizer và từ vựng. Các bước chuẩn bị dữ liệu gồm kiểm tra cặp câu, lọc câu không hợp lệ, chuẩn hóa văn bản và chuyển câu thành chuỗi token. Tập con huấn luyện sẽ được chọn từ train với seed cố định để phù hợp tài nguyên GPU miễn phí.

3 Phương pháp

Seq2Seq LSTM với Attention. Mô hình gồm encoder LSTM biểu diễn câu nguồn và decoder LSTM sinh từng token tiếng Việt. Cơ chế Attention tính trọng số trên các hidden state của encoder để hình thành context vector tại mỗi bước giải mã. Nhóm tự xây dựng các thành phần encoder, decoder và Attention.

Transformer. Nhóm tự xây dựng Transformer nhỏ theo Vaswani et al. (2017), gồm positional encoding, multi-head attention, feed-forward network, residual connection và layer normalization. Decoder sử dụng causal mask để không nhìn thấy các token tương lai.

Đối chứng. Hai mô hình được huấn luyện và đánh giá trên cùng tập dữ liệu và cùng quy trình tiền xử lý. Các cấu hình và ngân sách tính toán sẽ được ghi nhận để việc so sánh minh bạch.

4 Thiết kế thực nghiệm

Nhóm dự kiến sử dụng PyTorch và GPU miễn phí trên Kaggle hoặc Google Colab. Quá trình huấn luyện sẽ theo dõi training loss, validation loss, thời gian mỗi epoch và lưu checkpoint của mô hình tốt nhất trên tập validation.

Chất lượng dịch được đánh giá bằng **corpus BLEU** (Papineni et al., 2002). Nhóm sử dụng cùng tập test, cùng phương pháp giải mã và cấu hình đánh giá được công bố rõ ràng. Ngoài BLEU, nhóm phân tích các trường hợp dịch thiếu từ, sai nghĩa và câu dài; đồng thời trực quan hóa attention map.

5 Kế hoạch và phân công

Tuần 1: Khảo sát bài báo, kiểm tra PhoMT, chuẩn bị môi trường và Proposal.

Tuần 2: Hoàn thiện pipeline dữ liệu, tokenizer, baseline và huấn luyện thử.

Tuần 3: Hoàn thiện hai mô hình, checkpoint và báo cáo tiến độ.

Tuần 4: Huấn luyện, so sánh BLEU và thực hiện ablation.

Tuần 5: Phân tích lỗi, trực quan hóa attention và soạn báo cáo.

Tuần 6: Hoàn thiện báo cáo ACL, slide và demo; chuẩn bị bảo vệ cá nhân.

Tú: Dữ liệu, tokenizer, DataLoader, BLEU và tổng hợp Proposal.

Trung: Seq2Seq Attention, giải mã, demo và báo cáo tiến độ.

Đức: Transformer, huấn luyện, checkpoint, logging và tổng hợp báo cáo cuối.

Các thành viên cùng tham gia kiểm thử, đánh giá kết quả, review Pull Request và chuẩn bị trả lời vấn đáp.

6 Kết luận

Đề tài hướng đến một hệ thống dịch máy Anh–Việt có mã nguồn tự triển khai, quy trình thực nghiệm tái lập được và phân tích có căn cứ về ưu, nhược điểm của Seq2Seq Attention và Transformer.

References

Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural machine translation by jointly learning to align and translate. In *International Conference on Learning Representations*.

Long Doan, Linh The Nguyen, Nguyen Luong Tran, Thai Hoang, and Dat Quoc Nguyen. 2021. PhoMT: A high-quality and large-scale benchmark dataset for vietnamese-english machine translation. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 4495–4503. Association for Computational Linguistics.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: A method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318. Association for Computational Linguistics.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.