Dịch máy Anh–Việt sử dụng Seq2Seq LSTM với Attention và Transformer: Đề xuất nghiên cứu

Nguyễn Tất Tú: 24022481 Nguyễn Văn Trung: 24022475 Dương Hoàng Đức:
Nhóm: 1

Abstract

Đề tài nghiên cứu bài toán dịch máy thần kinh từ tiếng Anh sang tiếng Việt bằng hai kiến trúc: Seq2Seq LSTM kết hợp Attention và Transformer Encoder–Decoder. Nhóm sử dụng bộ dữ liệu song ngữ PhoMT, xây dựng quy trình tiền xử lý, huấn luyện và đánh giá thống nhất. Hai mô hình được so sánh bằng corpus BLEU, thời gian huấn luyện và phân tích lỗi dịch. Nghiên cứu tập trung vào tự cài đặt các thành phần cốt lõi và trực quan hóa attention. Do giới hạn tài nguyên, nhóm dự kiến sử dụng tập con PhoMT cùng GPU miễn phí trên Kaggle hoặc Google Colab.

1 Giới thiệu

Dịch máy thần kinh (Neural Machine Translation, NMT) sử dụng mạng học sâu để chuyển đổi một chuỗi ngôn ngữ nguồn thành chuỗi ngôn ngữ đích. Kiến trúc Seq2Seq sử dụng encoder và decoder để xử lý dữ liệu chuỗi. Cơ chế Attention giúp decoder tập trung vào các vị trí khác nhau của câu nguồn (Bahdanau et al., 2015).

Transformer sử dụng self-attention thay cho cơ chế hồi quy, qua đó tăng khả năng xử lý song song trong huấn luyện (Vaswani et al., 2017).

Mục tiêu của nghiên cứu là tự cài đặt, huấn luyện và so sánh Seq2Seq LSTM với Attention và Transformer trên cùng bài toán dịch **Anh sang Việt**, chú trọng chất lượng bản dịch, chi phí huấn luyện và các lỗi thường gặp.

2 Dữ liệu

Nhóm sử dụng PhoMT, bộ dữ liệu song ngữ Việt–Anh được giới thiệu bởi Doan et al. (2021). Dữ liệu gồm 3.015.869 cặp câu, trong đó tập train có 2.977.999 cặp, validation có 18.719 cặp và test có 19.151 cặp.

Nhóm giữ nguyên ba tập đã công bố. Tokenizer và từ vựng được xây dựng chỉ từ tập train nhằm tránh rò rỉ thông tin. Các bước tiền xử lý gồm kiểm tra cặp câu, chuẩn hóa văn bản, tokenization, giới hạn độ dài và tạo các batch có padding.

Do giới hạn tài nguyên tính toán, nhóm dự kiến sử dụng tập con được lấy từ tập train với random seed cố định. Tập validation được dùng để lựa chọn checkpoint; tập test chỉ dùng để đánh giá cuối cùng.

3 Phương pháp

Seq2Seq LSTM với Attention. Mô hình gồm encoder LSTM biểu diễn câu tiếng Anh và decoder LSTM sinh lần lượt các token tiếng Việt. Tại mỗi bước giải mã, Attention xác định trọng số liên quan giữa trạng thái decoder và các trạng thái encoder, sau đó tạo context vector. Nhóm tự xây dựng encoder, decoder, Attention và quá trình giải mã.

Transformer. Nhóm tự xây dựng Transformer Encoder–Decoder theo Vaswani et al. (2017), gồm positional encoding, multi-head attention, feed-forward network, residual connection và layer normalization. Decoder sử dụng causal mask để không truy cập token tương lai.

Đối chứng. Hai mô hình sử dụng cùng bộ dữ liệu và quy trình đánh giá. Cấu hình mô hình, số tham số, ngân sách huấn luyện và chiến lược giải mã được ghi nhận để hỗ trợ so sánh công bằng.

4 Thiết kế thực nghiệm

Nhóm dự kiến triển khai bằng PyTorch, sử dụng GPU miễn phí trên Kaggle hoặc Google Colab. Trong quá trình huấn luyện, nhóm theo dõi training loss, validation loss, thời gian mỗi epoch và lưu checkpoint có chất lượng validation tốt nhất.

Chất lượng dịch được đánh giá bằng **corpus BLEU** (Papineni et al., 2002). Nhóm sử dụng SacreBLEU và báo cáo cấu hình tokenization để kết quả có thể tái lập. Cả hai mô hình được kiểm thử trên cùng tập test.

Ngoài kết quả định lượng, nhóm phân tích các câu dịch sai nghĩa, thiếu thông tin hoặc gặp khó khăn với câu dài; đồng thời trực quan hóa attention map. Nhóm dự kiến thực hiện ablation để đánh giá vai trò của các thành phần kiến trúc.

5 Kế hoạch và phân công

Tuần 1: Khảo sát tài liệu, kiểm tra PhoMT, khởi tạo GitHub và hoàn thành Proposal.

Tuần 2: Hoàn thiện pipeline dữ liệu, tokenizer, baseline và huấn luyện thử.

Tuần 3: Xây dựng hai mô hình, checkpoint và báo cáo tiến độ.

Tuần 4: Thực nghiệm, đánh giá BLEU, điều chỉnh siêu tham số và ablation.

Tuần 5: Phân tích lỗi, trực quan hóa attention và viết bản thảo báo cáo.

Tuần 6: Hoàn thiện báo cáo ACL, slide, demo và chuẩn bị bảo vệ cá nhân.

Tú: PhoMT, tokenizer, DataLoader, BLEU, đánh giá và tổng hợp Proposal.

Trung: Seq2Seq LSTM Attention, giải mã, demo và báo cáo tiến độ.

Đức: Transformer, huấn luyện, checkpoint, logging và tổng hợp báo cáo cuối kỳ.

Các thành viên phối hợp kiểm thử, review Pull Request và phân tích kết quả.

6 Kết luận

Nghiên cứu hướng đến một hệ thống dịch máy Anh–Việt có mã nguồn tự triển khai, quy trình thực nghiệm tái lập được và đánh giá rõ ràng sự khác biệt giữa Seq2Seq Attention và Transformer trong điều kiện tài nguyên tính toán hạn chế.

References

Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural machine translation by jointly learning to align and translate. In *International Conference on Learning Representations*.

Long Doan, Linh The Nguyen, Nguyen Luong Tran, Thai Hoang, and Dat Quoc Nguyen. 2021. PhoMT: A high-quality and large-scale benchmark dataset for vietnamese-english machine translation. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 4495–4503. Association for Computational Linguistics.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318. Association for Computational Linguistics.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.