Xây dựng và so sánh hai mô hình dịch máy Anh–Việt: Seq2Seq LSTM với Attention và Transformer

Nguyễn Tất Tú: 24022481 **Nguyễn Văn Trung: 24022475** **Dương Hoàng Đức: 24022290**
Nhóm: 1

Abstract

Đề tài tập trung xây dựng, huấn luyện và so sánh hai mô hình dịch máy thần kinh từ tiếng Anh sang tiếng Việt: Seq2Seq LSTM kết hợp cơ chế Attention và Transformer Encoder–Decoder. Nhóm sử dụng bộ dữ liệu song ngữ IWSLT'15 English–Vietnamese để xây dựng quy trình tiền xử lý, huấn luyện và đánh giá thống nhất. Hai mô hình được tự cài đặt bằng PyTorch, không sử dụng các mô hình dịch đã huấn luyện sẵn. Nghiên cứu so sánh chất lượng bản dịch bằng corpus BLEU, thời gian huấn luyện, hiệu quả tính toán và khả năng xử lý câu có độ dài khác nhau. Ngoài đánh giá định lượng, nhóm phân tích các trường hợp dịch sai và trực quan hóa Attention nhằm làm rõ ưu điểm, hạn chế của từng kiến trúc. Các thí nghiệm dự kiến được thực hiện trên GPU miễn phí và hướng đến quy trình có khả năng tái lập.

1 Giới thiệu

Dịch máy thần kinh (Neural Machine Translation, NMT) sử dụng mạng học sâu để chuyển đổi một chuỗi ngôn ngữ nguồn thành chuỗi ngôn ngữ đích. Kiến trúc Seq2Seq sử dụng encoder và decoder để xử lý dữ liệu chuỗi. Khi kết hợp với Attention, decoder có thể tập trung vào những vị trí liên quan trong câu nguồn(Bahdanau et al., 2015).

Transformer sử dụng self-attention thay cho cơ chế hồi quy, qua đó tăng khả năng xử lý song song trong huấn luyện (Vaswani et al., 2017).

Mục tiêu của đề tài là **xây dựng và so sánh hai mô hình** Seq2Seq LSTM với Attention và Transformer trên cùng bài toán dịch **Anh sang Việt**. Nhóm tập trung đánh giá chất lượng dịch, chi phí tính toán và những lỗi thường gặp, thay vì chỉ triển khai mô hình có sẵn.

2 Dữ liệu

Nghiên cứu sử dụng bộ dữ liệu IWSLT'15 English–Vietnamese, được cung cấp thông qua Stanford NLP và sử dụng trong nghiên cứu của Luong and Manning (2015).

Bộ dữ liệu gồm 133.317 cặp câu huấn luyện, 1.553 cặp câu validation (`tst2012`) và 1.268 cặp câu kiểm thử (`tst2013`). Mỗi cặp gồm một câu tiếng Anh và một câu tiếng Việt tương ứng.

Nhóm giữ nguyên cách chia dữ liệu và chỉ xây dựng tokenizer, từ vựng trên tập train. Quy trình tiền xử lý gồm kiểm tra cặp câu, chuẩn hóa văn bản, tokenization, thêm token đặc biệt, padding và giới hạn độ dài chuỗi.

Tập validation được dùng để điều chỉnh siêu tham số và lựa chọn checkpoint. Tập test chỉ sử dụng để đánh giá cuối cùng. Hai mô hình được huấn luyện trên cùng dữ liệu nhằm bảo đảm tính nhất quán.

3 Phương pháp

Seq2Seq LSTM với Attention. Mô hình gồm encoder LSTM biểu diễn câu tiếng Anh và decoder LSTM sinh lần lượt các token tiếng Việt. Tại mỗi bước giải mã, Attention xác định trọng số liên quan giữa trạng thái decoder và các trạng thái encoder, sau đó tạo context vector. Nhóm tự xây dựng encoder, decoder, Attention và quá trình giải mã.

Mô hình 2: Transformer. Nhóm xây dựng Transformer Encoder–Decoder theo Vaswani et al. (2017). Các thành phần

được tự cài đặt gồm embedding, positional encoding, multi-head attention, feed-forward network, residual connection và layer normalization. Decoder sử dụng causal mask để tránh truy cập token tương lai.

Đối chứng. Hai mô hình sử dụng cùng tập train, validation, test, tokenizer và cấu hình đánh giá. Nhóm ghi nhận số tham số, siêu tham số, phần cứng và ngân sách huấn luyện. Các lựa chọn tối ưu riêng cho từng kiến trúc được công bố rõ ràng để bảo đảm tính minh bạch.

4 Thiết kế thực nghiệm

Hai mô hình được tự cài đặt bằng PyTorch, huấn luyện trên GPU miễn phí từ Kaggle hoặc Google Colab. Nhóm theo dõi training loss, validation loss, thời gian huấn luyện và lưu checkpoint tốt nhất trên tập validation.

Chất lượng dịch được đánh giá bằng **corpus BLEU** (Papineni et al., 2002) thông qua SacreBLEU trên cùng tập test và cấu hình đánh giá thống nhất.

Nhóm so sánh BLEU, số tham số, thời gian huấn luyện và chất lượng dịch theo độ dài câu. Ngoài ra, nhóm phân tích các lỗi dịch, trực quan hóa attention map và thực hiện ablation trong phạm vi tài nguyên cho phép.

5 Kế hoạch và phân công

Tuần 1: Nghiên cứu tài liệu, chuẩn bị IWSLT'15 và Proposal.

Tuần 2: Xây dựng pipeline dữ liệu, tokenizer và baseline.

Tuần 3: Hoàn thiện hai mô hình, chạy thử và báo cáo tiến độ.

Tuần 4: Huấn luyện, so sánh BLEU, tốc độ và thực hiện ablation.

Tuần 5: Phân tích lỗi, trực quan hóa attention và viết báo cáo.

Tuần 6: Hoàn thiện báo cáo ACL, slide, demo và bảo vệ.

Nguyễn Tất Tú: Dữ liệu IWSLT'15, tokenizer, DataLoader, BLEU và Proposal.

Nguyễn Văn Trung: Seq2Seq LSTM Attention, giải mã, demo và báo cáo tiến độ.

Dương Hoàng Đức: Transformer, huấn luyện, checkpoint, logging và báo cáo cuối kỳ.

Cả nhóm cùng kiểm thử, phân tích kết quả và review Pull Request.

6 Kết luận

Đề tài hướng đến việc xây dựng hoàn chỉnh hai mô hình dịch máy Anh–Việt và tiến hành so sánh thực nghiệm trong cùng điều kiện. Nghiên cứu giúp làm rõ điểm mạnh, hạn chế của Seq2Seq Attention và Transformer về chất lượng dịch và hiệu quả tính toán, đồng thời xây dựng mã nguồn có khả năng tái lập phục vụ học tập và nghiên cứu.

References

Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural machine translation by jointly learning to align and translate. In *International Conference on Learning Representations*.

Minh-Thang Luong and Christopher Manning. 2015. Stanford neural machine translation systems for spoken language domains. In *Proceedings of the 12th International Workshop on Spoken Language Translation: Evaluation Campaign*, pages 76–79, Da Nang, Vietnam.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318. Association for Computational Linguistics.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.