Xây dựng và so sánh hai mô hình dịch máy Anh–Việt: Seq2Seq LSTM với Attention và Transformer

Nguyễn Tất Tú: 24022481 Nguyễn Văn Trung: 24022475 Dương Hoàng Đức: 24022290
Nhóm: 1

Abstract

Đề tài tự cài đặt bằng PyTorch và so sánh hai mô hình dịch máy Anh–Việt, Seq2Seq LSTM với Attention và Transformer, trên IWSLT'15 với cùng tokenizer, giải mã và cách đánh giá. Nhóm so sánh SacreBLEU, chi phí huấn luyện và hiệu quả theo độ dài câu, đồng thời trực quan hóa attention và phân tích lỗi.

1 Giới thiệu

Dịch máy thần kinh (Neural Machine Translation, NMT) chuyển một chuỗi ngôn ngữ nguồn thành chuỗi ngôn ngữ đích bằng mạng học sâu. Kiến trúc Seq2Seq dùng encoder và decoder; khi kết hợp với Attention, decoder tập trung vào những vị trí liên quan trong câu nguồn (Bahdanau et al., 2015). Transformer thay cơ chế hồi quy bằng self-attention, giúp huấn luyện song song hiệu quả hơn (Vaswani et al., 2017).

Mục tiêu của đề tài là xây dựng và so sánh hai mô hình trên cùng bài toán dịch Anh sang Việt, tập trung vào chất lượng dịch, chi phí tính toán và các lỗi thường gặp. Chúng tôi kỳ vọng Transformer cho BLEU cao hơn và huấn luyện nhanh hơn mỗi epoch, trong khi LSTM có thể cạnh tranh trên câu ngắn.

2 Dữ liệu

Nghiên cứu dùng IWSLT'15 English–Vietnamese (Luong and Manning, 2015) gồm 133.317 cặp câu huấn luyện, 1.553 cặp validation (`tst2012`) và 1.268 cặp kiểm thử (`tst2013`). Nhóm giữ nguyên cách chia. Validation dùng để chọn siêu tham số và checkpoint; test chỉ dùng cho đánh giá cuối.

Tiền xử lý gồm chuẩn hóa Unicode NFC (giữ nguyên chữ hoa), loại cặp câu dài quá 100 token hoặc có tỉ lệ độ dài nguồn/đích lệch quá 2,5 lần, thêm token đặc biệt và padding. Tokenizer mặc định là SentencePiece BPE huấn luyện chung trên phần train của hai ngôn ngữ, từ vựng 8.000 token, dùng chung embedding giữa encoder và decoder.

3 Phương pháp

Phạm vi. *Bắt buộc:* hai mô hình, SacreBLEU, attention, ablation (Mục 4). *Mở rộng, theo thứ tự nếu còn thời gian:* (1) so sánh tokenizer BPE, SentencePiece, mức từ; (2) fine-tune EnViT5 hoặc mBART làm mốc tham chiếu.

Mô hình 1: Seq2Seq LSTM với Attention. Encoder BiLSTM biểu diễn câu tiếng Anh, decoder LSTM sinh lần lượt các token tiếng Việt. Tại mỗi bước, Attention kiểu Luong (general) tính trọng số giữa trạng thái decoder và các trạng thái encoder để tạo context vector, kết hợp input feeding.

Mô hình 2: Transformer. Transformer Encoder–Decoder nhỏ theo Vaswani et al. (2017), tự cài đặt embedding, positional encoding, multi-head attention, feed-forward network, residual connection, layer normalization; decoder dùng causal mask. Mô hình được thu nhỏ so với bản gốc để tránh overfit trên dữ liệu 133 nghìn cặp câu.

Tiêu chí công bằng. Hai mô hình cùng dữ liệu, tokenizer, giải mã, GPU và ngân

	Seq2Seq LSTM + Attention	**Transformer nhỏ**
Encoder	BiLSTM 2 lớp, hidden 512 mỗi chiều	3 lớp
Decoder	LSTM 2 lớp, hidden 512	3 lớp, causal mask
Attention	Luong (general)	Multi-head, 4 head
Kích thước	embedding 512	$d_{model} = 512$, $d_{ff} = 1024$
Dropout	0,3	0,3
Optimizer	Adam, lr 10^{-3}, gradient clip 1,0	Adam ($\beta_2 = 0{,}98$), lr đỉnh $5 \cdot 10^{-4}$, warmup 2.000 bước
Chung	label smoothing 0,1; embedding decoder dùng chung với lớp đầu ra; mixed precision	
Tham số (ước tính)	$\sim$22M	$\sim$20M

Table 1: Cấu hình dự kiến. Số tham số sẽ được đo lại bằng mã nguồn.

sách tối đa 30 epoch với early stopping (kiên nhẫn 5). So sánh chính theo cùng cỡ tham số (Bảng 1); thời gian huấn luyện chỉ được báo cáo kèm.

4 Thiết kế thực nghiệm

Hai mô hình huấn luyện bằng PyTorch trên GPU miễn phí (Kaggle hoặc Colab); nhóm theo dõi training/validation loss và lưu checkpoint tốt nhất trên validation.

Đánh giá. Corpus BLEU (Papineni et al., 2002) qua SacreBLEU (tokenization mặc định) trên văn bản đã detokenize, tập `tst2013` (không so sánh trực tiếp với bài báo dùng quy ước khác). Giải mã bằng beam search (beam 5, chuẩn hóa độ dài, độ dài tối đa bằng độ dài nguồn cộng 50), dùng chung cho cả hai mô hình. Mỗi mô hình chạy một seed; nếu còn thời gian, ước lượng khoảng tin cậy bằng paired bootstrap.

So sánh. BLEU tổng thể; BLEU theo bốn nhóm độ dài nguồn ($\leq$10, 11–20, 21–30, $>$30 từ); số tham số, thời gian mỗi epoch, tổng thời gian đến checkpoint tốt nhất và bộ nhớ GPU đỉnh.

Ablation. (A1) greedy so với beam search; (A2) Transformer 2 so với 3 lớp; (A3) LSTM có và không có Attention.

Attention và phân tích lỗi. Với LSTM, vẽ trọng số attention của các bước giải mã. Với Transformer, vẽ cross-attention lớp decoder cuối: trung bình các head và từng head cho 2–3 câu minh họa. Phân tích lỗi trên 50 câu test (phân tầng theo độ dài), gán vào bốn nhóm: thiếu hoặc lặp từ, sai từ vựng, sai trật tự, sai tên riêng hoặc số.

5 Phân công và rủi ro

Tiến độ theo timeline chung của môn học; dưới đây là phân công và phương án dự phòng:

Nguyễn Tất Tú: dữ liệu IWSLT'15, tokenizer, DataLoader, BLEU và Proposal.

Nguyễn Văn Trung: Seq2Seq LSTM Attention, beam search dùng chung, demo và báo cáo tiến độ.

Dương Hoàng Đức (nhóm trưởng): Transformer, huấn luyện, checkpoint, logging và báo cáo cuối kỳ.

Rủi ro. (i) Giới hạn phiên Colab/Kaggle: lưu checkpoint mỗi epoch. (ii) Transformer overfit hoặc hội tụ chậm: tăng dropout, giảm xuống 2 lớp hoặc tăng warmup. (iii) Chậm tiến độ: bỏ En-ViT5/mBART trước, rồi so sánh tokenizer; giữ nguyên phần bắt buộc.

References

Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. Neural machine translation by jointly learning to align and translate. In *International Conference on Learning Representations*.

Minh-Thang Luong and Christopher Manning. 2015. Stanford neural machine translation systems for spoken language domains. In *Proceedings of the 12th International Workshop on Spoken Language Translation: Evaluation Campaign*, pages 76–79, Da Nang, Vietnam.

Kishore Papineni, Salim Roukos, Todd Ward, and Wei-Jing Zhu. 2002. BLEU: a method for automatic evaluation of machine translation. In *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics*, pages 311–318. Association for Computational Linguistics.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.